



Matemática e Estatística para Computação

Turma B - 0226 - Campus Virtual - Virtual - 23/02/26 GV2

Professor Dr. Romes Heriberto

Aluno: Juliana Siqueira Nogueira da Silva

RA: 72600772

Atividade de Sistematização (Relatório): Visualizando a Teoria

Brasília - DF,
2026.

ÍNDICE

CAPÍTULO 1. Probabilidade Básica (Basic Probability)	4
CAPÍTULO 2. Probabilidade Composta (Compound Probability)	7
CAPÍTULO 3. Distribuições de Probabilidade (Probability Distributions)	10
CAPÍTULO 4. Inferência Freqüentista (Frequentist Inference)	13
CAPÍTULO 5. Inferência Bayesiana (Bayesian Inference)	16
CAPÍTULO 6. Análise de Regressão (Regression Analysis)	19
Conclusão	23
Referências	24


Introdução

A estatística e a probabilidade são pilares fundamentais da ciência de dados e da tecnologia moderna. No entanto, seus conceitos costumam parecer abstratos quando apresentados apenas por meio de fórmulas. Com o objetivo de tornar esse aprendizado mais visual e interativo, esta atividade utilizou a plataforma Seeing Theory, desenvolvida pela Brown University, que transforma conceitos estatísticos em simulações animadas e intuitivas.

Ao longo deste relatório, são explorados seis capítulos da plataforma: Probabilidade Básica, Probabilidade Composta, Distribuições de Probabilidade, Inferência Frequentista, Inferência Bayesiana e Análise de Regressão, com três experimentos interativos documentados em cada um. Para cada simulação, são apresentados a explicação do conceito matemático observado e um exemplo de aplicação prática na área de tecnologia e dados.

Capítulo 1: Probabilidade Básica

[Capítulo 1 - Print 1] Eventos Aleatórios (Chance Events): Lançamento de Moeda



Explicação do Conceito

A simulação do lançamento de moeda demonstra o conceito fundamental de espaço amostral e probabilidade simples. O experimento exibe dois resultados possíveis (Cara e Coroa), cada um com probabilidade teórica de 50%. Ao lançar a moeda repetidas vezes, observa-se empiricamente a Lei dos Grandes Números: conforme o número de lançamentos aumenta, a frequência relativa observada converge para a probabilidade teórica de 0,5. No início, os resultados podem se desviar significativamente de 50%, mas com n grande, a proporção estabiliza próxima ao valor esperado. O gráfico de barras exibe visualmente a diferença entre os resultados observados e as probabilidades teóricas.

Aplicação Prática em Tecnologia

Em sistemas de detecção de fraudes, algoritmos de machine learning utilizam a Lei dos Grandes Números para treinar modelos preditivos: quanto maior o conjunto de dados de treinamento, mais precisa tende a ser a estimativa de probabilidade de um evento (exemplo: classificar uma transação como fraudulenta ou legítima). Empresas como fintechs processam milhões de

transações diariamente para que esses estimadores se aproximem dos parâmetros populacionais reais.

[Capítulo 1 - Print 2] - Expectativa (Expectation): Lançamento de Dado



Explicação do Conceito


A simulação do dado ilustra o conceito de Valor Esperado $E(X)$, definido matematicamente como $E(X) = \sum X_i \cdot P(X_i)$. Para um dado justo de 6 faces, o valor esperado é 3,5, um número que nunca ocorre como resultado isolado, mas representa a média de longo prazo. O gráfico interativo mostra a média amostral correndo convergindo ao valor de expectativa 3,5 conforme o número de lançamentos aumenta. Ao tornar o dado viciado (ajustando as probabilidades das faces), o valor esperado muda, demonstrando como a distribuição de probabilidade define o centro de massa da variável aleatória.

Aplicação Prática em Tecnologia

Na área de tecnologia, o valor esperado é central ao cálculo de SLA (Service Level Agreement): engenheiros de confiabilidade calculam o tempo médio

esperado entre falhas (MTTF) para prever manutenção preventiva em servidores e infraestrutura de nuvem. Plataformas de cloud computing como AWS e Azure monitoram continuamente o valor esperado de disponibilidade para garantir o cumprimento dos acordos de nível de serviço.

[Capítulo 1 - Print 3] - Variância (Variance): Baralho de Cartas



Explicação do Conceito

Enquanto a expectativa mede a centralidade, a variância quantifica a dispersão de uma variável aleatória em torno de sua média, dada por $\text{Var}(X) = E[(X - E[X])^2]$. A simulação com um baralho de 10 cartas (valores de 1 a 10) permite visualizar como a média dos quadrados das diferenças (linha verde) converge para a verdadeira variância (linha azul) conforme mais cartas são sorteadas. A variância calculada foi de 8,25, com média de 8,05, refletindo a dispersão dos valores. É possível alternar quais cartas compõem o baralho, modificando dinamicamente a variância teórica.


Aplicação Prática em Tecnologia

Em análise de risco de sistemas fintech, a variância (e seu derivado, o desvio padrão) é usada para medir a volatilidade de ativos ou a variação de latência em

microsserviços. Sistemas de monitoramento de performance como Datadog e New Relic alertam automaticamente quando a variância do tempo de resposta excede um limiar crítico pré-definido em contratos de SLA.

Capítulo 2: Probabilidade Composta

[Capítulo 2 - Print 1] Teoria dos Conjuntos (Set Theory): Diagrama de Venn



Explicação do Conceito

A teoria dos conjuntos fornece a linguagem formal para descrever eventos compostos. O diagrama de Venn interativo permite construir expressões booleanas envolvendo conjuntos A, B e C, visualizando operações como união ($\cup$), interseção ($\cap$), complemento e diferença. A região destacada em amarelo representa a interseção $A \cap B$, ou seja, os elementos pertencentes simultaneamente aos dois conjuntos. Essa representação visual facilita a compreensão de como a probabilidade de eventos conjuntos é calculada a partir das áreas relativas no espaço amostral total.

Aplicação Prática em Tecnologia

Bancos de dados relacionais usam álgebra de conjuntos diretamente nas consultas SQL: cláusulas UNION, INTERSECT e EXCEPT implementam as

operações de união, interseção e diferença entre conjuntos de resultados. Isso é fundamental para análise de dados de usuários com múltiplos atributos, como segmentar clientes que pertencem a dois segmentos de mercado simultaneamente em plataformas de CRM.

[Capítulo 2 - Print 2] Contagem (Counting): Permutações e Combinações

This site is archived for reference

Chapter 2: Compound Probability

Counting

It can be surprisingly difficult to count the number of sequences or sets satisfying certain conditions. For example, consider a bag of marbles in which each marble is a different color. If we draw marbles one at a time from the bag without replacement, how many different ordered sequences (permutations) of the marbles are possible? How many different unordered sets (combinations) of the marbles are possible?

☒ Permutation ☐ Combination

Choose how many marbles the bag should contain.

Click on the table below to visualize all possible permutations or combinations of the marbles.

n	0	1	2	3	4
P _n	1	3	6	24	24

Mostrar ícones ocultos

Explicação do Conceito


A simulação de contagem com bolinhas coloridas ilustra a distinção entre permutações (sequências ordenadas) e combinações (conjuntos não ordenados). Para 3 bolinhas (A, B, C), o número de permutações de 2 elementos é $P(3,2) = 6$ sequências distintas (AB, AC, BA, BC, CA, CB), enquanto as combinações são apenas 3 (AB, AC, BC). O diagrama de árvore torna visual como cada galho representa uma escolha sequencial, e os nós folha representam os resultados possíveis.

Aplicação Prática em Tecnologia

Algoritmos de criptografia e geração de senhas dependem diretamente da combinatória: o número de senhas possíveis com N caracteres distintos de um alfabeto de tamanho K é calculado por permutações, determinando a força de

resistência a ataques de força bruta. Por exemplo, uma senha alfanumérica de 8 caracteres possui aproximadamente 218 trilhões de combinações possíveis.

[Capítulo 2 - Print 3] Probabilidade Condicional (Conditional Probability)



Explicação do Conceito


A probabilidade condicional $P(A|B)$ representa a probabilidade do evento A ocorrer dado que B já ocorreu. Matematicamente, $P(A|B) = P(A \cap B) / P(B)$. A simulação demonstra como o espaço amostral encolhe quando uma condição é imposta: ao saber que o dia anterior foi chuvoso, apenas os dias chuvosos formam o novo universo, e recalculamos a probabilidade de chuva dentro desse subconjunto. As barras coloridas mostram $P(A|B)$, $P(B|A)$ e $P(A|C)$, evidenciando como a condicionalidade transforma as probabilidades marginais.

Aplicação Prática em Tecnologia

Sistemas de recomendação (como os da Netflix ou Spotify) são construídos sobre probabilidade condicional: $P(\text{usuário gosta de } Y \mid \text{gostou de } X)$ é estimada a partir do comportamento histórico de milhões de usuários, gerando sugestões personalizadas em tempo real. O algoritmo de filtragem colaborativa atualiza continuamente essas probabilidades condicionais à medida que novos dados de consumo são coletados.

Capítulo 3: Distribuições de Probabilidade

[Capítulo 3 – Print 1] Variáveis Aleatórias (Random Variables)




Explicação do Conceito

Uma variável aleatória é uma função que atribui um valor numérico real a cada resultado do espaço amostral. A simulação permite ao usuário definir manualmente regiões do espaço de probabilidade (representado por células hexagonais) e associar valores numéricos a cada região colorida. Ao amostrar do espaço de probabilidade, é gerada a distribuição empírica da variável aleatória criada. Esse experimento demonstra como qualquer evento aleatório pode ser codificado numericamente, possibilitando cálculos matemáticos formais sobre fenômenos incertos.

Aplicação Prática em Tecnologia

Em machine learning, variáveis aleatórias modelam atributos incertos de dados de entrada: a probabilidade de um pixel pertencer a uma determinada classe (segmentação de imagem por redes neurais convolucionais) é modelada como uma variável aleatória cujo espaço de probabilidade é aprendido durante o treinamento do modelo. Isso fundamenta tarefas como reconhecimento facial e diagnóstico médico por imagem.

[Capítulo 3 – Print 2] Discretas e Contínuas: Distribuição Geométrica




Explicação do Conceito

Existem dois tipos principais de distribuições de probabilidade: discretas (número finito ou contável de valores) e contínuas (valores em intervalos reais). A simulação apresenta a Distribuição Geométrica, que modela o número de tentativas necessárias para se observar o primeiro sucesso em experimentos de Bernoulli independentes. Com $p = 0,5$, a função de massa de probabilidade $f(x) = (1-p)^{x-1} \cdot p$ mostra uma distribuição decrescente, e a função de distribuição acumulada $F(x)$ (em laranja) cresce monotonamente de 0 a 1.

Aplicação Prática em Tecnologia

A distribuição geométrica modela o número de requisições necessárias até que um servidor responda com sucesso em sistemas distribuídos com taxa de falha conhecida. É usada em estratégias de retry com backoff exponencial em microserviços e APIs REST, orientando os timeouts configurados nas chamadas entre serviços em arquiteturas de microserviços.

[Capítulo 3 – Print 3] Teorema Central do Limite (Central Limit Theorem)



Explicação do Conceito


O Teorema Central do Limite (TCL) afirma que a distribuição da média amostral de variáveis aleatórias i.i.d. converge para uma distribuição Normal à medida que o tamanho da amostra cresce, independentemente da distribuição original. A simulação com parâmetros $\alpha = 3,00$ e $\beta = 3,20$ e tamanho de amostra = 5 mostra histogramas das médias amostrais convergindo para a curva normal teórica em amarelo. Mesmo partindo de uma distribuição assimétrica, com amostras maiores a distribuição das médias assume o formato de sino característico da Normal.

Aplicação Prática em Tecnologia

O TCL fundamenta testes A/B em produtos digitais: ao comparar métricas (taxa de clique, conversão) entre grupos de usuários, assume-se normalidade das médias amostrais para calcular valores-p e determinar se diferenças são estatisticamente significativas. Empresas como Google e Meta realizam milhares de testes A/B simultâneos baseados nesse princípio para otimizar produtos e interfaces digitais.

Capítulo 4: Inferência Frequentista

[Capítulo 4 – Print 1] Estimação Pontual (Point Estimation): Estimativa de π




Explicação do Conceito

A estimação pontual busca aproximar um parâmetro populacional desconhecido por meio de uma única estatística calculada da amostra. A simulação estima o valor de π usando o Método de Monte Carlo: pontos são lançados aleatoriamente sobre um quadrado contendo um círculo inscrito, e a razão entre pontos dentro do círculo e o total estima $\pi \approx 4 \cdot (m/n)$. Com $n = 280$ amostras, o estimador converge para $\hat{\pi} \approx 3,109$. O estimador é considerado não-viesado e consistente: à medida que n cresce, a estimativa se aproxima do parâmetro real.

Aplicação Prática em Tecnologia

O Método de Monte Carlo é amplamente usado em simulações financeiras e renderização gráfica. Engines de path tracing em jogos 3D com ray tracing utilizam amostragem aleatória massiva para calcular iluminação global, convergindo para a solução real à medida que mais raios são amostrados por pixel. O mesmo método é usado em simulações de risco em portfólios de investimento e precificação de derivativos financeiros.

[Capítulo 4 – Print 2] Intervalos de Confiança (Confidence Interval)




Explicação do Conceito

Diferente dos estimadores pontuais, os intervalos de confiança fornecem uma faixa de valores possíveis para o parâmetro, associada a um nível de confiança ($1 - \alpha$). Com $n = 20$ e nível de confiança de 60%, a simulação gera múltiplos intervalos a partir de amostras da distribuição Normal. As barras em verde contêm o parâmetro μ real (linha pontilhada), enquanto as barras em rosa não o contêm. Observa-se empiricamente que cerca de 60% dos intervalos gerados capturam μ , exatamente o que o nível de confiança promete.

Aplicação Prática em Tecnologia

Sistemas de monitoramento de infraestrutura como Datadog e Prometheus usam intervalos de confiança para alertas inteligentes: em vez de alertar sobre qualquer desvio pontual, o sistema define bandas de confiança ao redor da média histórica de métricas como CPU e latência, disparando alarmes apenas quando o valor sai estatisticamente da faixa esperada, reduzindo falsos positivos.

[Capítulo 4 – Print 3] Bootstrap: Reamostragem para Estimação



Explicação do Conceito



O Bootstrap é uma técnica computacional de reamostragem que estima propriedades de um estimador (como seu erro padrão) sem depender de fórmulas analíticas fechadas. Partindo de uma distribuição Exponencial, uma amostra de $n = 12$ observações é gerada, e então reamostrada com reposição várias vezes. Cada reamostragem produz uma estimativa da média, gerando uma distribuição empírica (histograma amarelo) que aproxima a distribuição amostral do estimador. Isso permite calcular intervalos de confiança mesmo para estatísticas complexas sem solução analítica.

Aplicação Prática em Tecnologia

Em ciência de dados, o Bootstrap é utilizado para criar Random Forests: algoritmos de ensemble em que cada árvore de decisão é treinada sobre uma reamostragem bootstrap do conjunto de dados original. Essa técnica reduz overfitting e aumenta a robustez das previsões em tarefas de classificação e regressão. É também usada para validar a estabilidade de coeficientes em modelos econométricos.

Capítulo 5: Inferência Bayesiana

[Capítulo 5 – Print 1] Teorema de Bayes: Diagnóstico Médico



Explicação do Conceito


O Teorema de Bayes formaliza como atualizar crenças à luz de novas evidências: $P(\text{Doença}|+) = P(+|\text{Doença}) \cdot P(\text{Doença}) / P(+)$. A simulação modela um teste diagnóstico de doença rara. Mesmo com um teste de alta precisão, se a prevalência (prior) da doença é muito baixa, um resultado positivo pode ter baixa probabilidade posterior de realmente indicar a doença, fenômeno chamado de paradoxo do falso positivo. A visualização com populações de pontos (azuis = saudáveis, vermelhos = doentes) torna intuitivo como a proporção de

verdadeiros positivos sobre todos os positivos depende criticamente da prevalência da doença.

Aplicação Prática em Tecnologia

Filtros de spam em e-mail (como no Gmail) são implementados com classificadores Bayesianos Ingênuos: a probabilidade de um e-mail ser spam dado o conjunto de palavras que contém é atualizada continuamente com novos exemplos de spam e ham reportados pelos usuários. O Teorema de Bayes permite que esses sistemas aprendam incrementalmente sem retreinar o modelo do zero a cada novo dado.

[Capítulo 5 – Print 2] Função de Verossimilhança (Likelihood Function)



Explicação do Conceito


A função de verossimilhança $L(\theta|x) = P(x|\theta)$ mede o quão compatível é um parâmetro θ com os dados observados x . Na simulação com distribuição Binomial $(3, \theta)$, uma amostra de $n = 10$ observações é gerada, e ao mover o slider roxo, visualiza-se como a verossimilhança varia em função de θ . O pico da curva de verossimilhança corresponde ao estimador de máxima verossimilhança

(MLE). A função de verossimilhança conecta a abordagem frequentista (MLE) e a bayesiana (usada como atualização da distribuição priori).

Aplicação Prática em Tecnologia

Modelos de linguagem de grande porte (LLMs) são treinados por minimização da verossimilhança negativa (cross-entropy loss) dos dados de treinamento: o modelo aprende os parâmetros θ que maximizam $P(\text{texto de treinamento} | \theta)$. O mesmo princípio se aplica ao treinamento de redes neurais em geral via gradiente descendente estocástico.

[Capítulo 5 – Print 3] De Priori a Posteriori (Prior to Posterior)



Explicação do Conceito

O núcleo da estatística Bayesiana é a atualização de crenças: começamos com uma distribuição a priori Beta (α , β) sobre o parâmetro p , representando nosso conhecimento inicial. À medida que novos dados (lançamentos de moeda) são observados, a posteriori é atualizada multiplicando a priori pela verossimilhança. Com $p = 0,90$, $\alpha = 2,52$ e $\beta = 0,30$, e acumulando 12 resultados (1 coroa, 11 caras), a distribuição posteriori concentrada próxima a 1,0 reflete que os dados


confirmam uma moeda bastante viciada. A posteriori torna-se a nova priori para dados futuros.

Aplicação Prática em Tecnologia

Sistemas de bandit algorithms (como Thompson Sampling) usam atualização Bayesiana em tempo real para otimização de anúncios digitais: a taxa de clique de cada anúncio começa com uma priori fraca (Beta uniforme) e é atualizada a cada impressão e clique, selecionando dinamicamente o anúncio com maior probabilidade posterior de sucesso, balanceando exploração e aproveitamento.

Capítulo 6: Análise de Regressão

[Capítulo 6 – Print 1] Mínimos Quadrados Ordinários (OLS): Quarteto de Anscombe



Explicação do Conceito


O método OLS (Ordinary Least Squares) estima os parâmetros de um modelo linear minimizando a soma dos quadrados dos resíduos (diferença entre valores observados e preditos). A simulação usa o Quarteto III de Anscombe: os quatro datasets têm a mesma linha de regressão ajustada ($\beta_0 = 3,00$, $\beta_1 = 0,50$), o mesmo R^2 e a mesma variância residual, mas padrões visuais completamente

diferentes. Isso demonstra que estatísticas resumidas idênticas podem corresponder a distribuições de dados radicalmente distintas, reforçando a importância de visualizar os dados antes de modelar.

Aplicação Prática em Tecnologia

Em engenharia de dados e analytics, modelos de regressão linear são usados para prever KPIs de negócio (como faturamento em função de investimento em marketing). A lição do Quarteto de Anscombe é aplicada diretamente: antes de construir pipelines de ML, boas práticas de engenharia de dados exigem análise exploratória visual (EDA) para detectar outliers, não-linearidades e padrões ocultos nos dados.

[Capítulo 6 – Print 2] Correlação: Dataset Iris de Anderson



Click on a cell of the correlation matrix to visualize the relationship between these traits.

	Sepal Length	Sepal Width	Petal Length	Petal Width
Sepal Length	1.00	-0.21	0.81	0.79
Sepal Width	-0.21	1.00	-0.60	-0.57
Petal Length	0.81	-0.60	1.00	0.98
Petal Width	0.79	-0.57	0.98	1.00


Explicação do Conceito

A correlação r mede a intensidade e direção da relação linear entre duas variáveis, assumindo valores de -1 a $+1$. A simulação usa o famoso Dataset Iris para explorar correlações entre atributos das flores. A matriz de correlação revela que Petal Length e Petal Width têm correlação altíssima ($r = 0,98$), enquanto Sepal Width e Petal Length têm correlação negativa moderada ($r = -0,60$). O gráfico de dispersão exibe a nuvem de pontos da relação selecionada, confirmando visualmente a força e direção da correlação.

Aplicação Prática em Tecnologia

Em seleção de features para modelos de machine learning, a análise de correlação é usada para identificar multicolinearidade: quando duas variáveis preditoras são altamente correlacionadas ($|r| > 0,9$), incluir ambas não agrega informação e pode prejudicar modelos como regressão logística e SVMs. Ferramentas como pandas e scikit-learn automatizam a geração da matriz de correlação no pré-processamento de dados.

[Capítulo 6 – Print 3] Análise de Variância (ANOVA)



Explicação do Conceito

A ANOVA é um método que generaliza o teste t para comparar as médias de dois ou mais grupos, testando se pelo menos um grupo possui média significativamente diferente dos demais. Decompõe a variação total em variação entre grupos (tratamento, SST) e variação dentro dos grupos (erro, SSE). Na simulação com Quartet X, a tabela ANOVA exibe SSE, SS Tratamento, $MSE = SSE/df$, estatística F e valor-p. Um valor-p elevado indica ausência de evidência estatística de diferença significativa entre as médias dos grupos analisados.

Aplicação Prática em Tecnologia

Em testes A/B multivariados de produtos digitais (testando simultaneamente múltiplas versões de uma interface de usuário), a ANOVA é usada para determinar se alguma variante produziu resultados significativamente diferentes das demais, controlando o erro de Tipo I inflado por múltiplas comparações. Plataformas como Optimizely e Google Optimize utilizam ANOVA internamente para comparação de grupos.

Conclusão

A realização desta atividade por meio da plataforma Seeing Theory permitiu transformar conceitos estatísticos muitas vezes abstratos em experiências visuais e interativas. Ao explorar os seis capítulos, desde a Probabilidade Básica até a Análise de Regressão, foi possível compreender na prática como fenômenos aleatórios se comportam, como estimativas são construídas a partir de amostras e como modelos matemáticos descrevem a incerteza do mundo real.

Mais do que memorizar fórmulas, a atividade evidenciou a aplicabilidade direta desses conceitos na área de tecnologia e dados: da detecção de fraudes ao treinamento de modelos de linguagem, da otimização de anúncios digitais à análise de infraestrutura em nuvem. Isso reforça que a estatística não é apenas uma disciplina teórica, mas uma ferramenta essencial para a tomada de decisão em ambientes tecnológicos cada vez mais orientados a dados.

REFERÊNCIAS

BROWN UNIVERSITY. ***Seeing Theory: A visual introduction to probability and statistics***. Disponível em: <https://seeing-theory.brown.edu>. Acesso em: 17 abr. 2026.

MONTGOMERY, Douglas C.; RUNGER, George C. ***Estatística aplicada e probabilidade para engenheiros***. 6. ed. Rio de Janeiro: LTC, 2016.

MORETTIN, Pedro A.; BUSSAB, Wilton O. ***Estatística básica***. 9. ed. São Paulo: Saraiva, 2017.

JAMES, Gareth et al. ***An introduction to statistical learning with applications in R***. 2. ed. New York: Springer, 2021. Disponível em: <https://www.statlearning.com>. Acesso em: 17 abr. 2026.

GRUS, Joel. ***Data science do zero: primeiras regras com o Python***. 2. ed. Rio de Janeiro: Alta Books, 2021.